当代人工智能作业四——Seq2Seq

2025年11月27日

Seq2Seq模型的设计与实现

- 本次作业要求同学们独立完成一个序列生成任务，包括模型设计、训练、评估与报告撰写。
- 提交截止时间：2025年12月31日 23:59
- 提交方式：提交至助教邮箱 51285903044@stu.ecnu.edu.cn
- 命名格式：学号_姓名_Seq2Seq.zip（不要上传数据集和模型文件！！！！！）
  - code/ # 源代码文件
  - report.pdf # 实验报告 ≤10页
  - README.md # 运行说明，能复现!
  - requirements.txt

数据集说明

1.Multi30k *https://huggingface.co/datasets/bentrevett/multi30k*

约 29,000 个英文描述作为训练集

- 1,014 个验证集样本
- 1,000 个测试集样本
- 每条样本通常是简洁、自然的图像描述句子（长度短、语法简单）

如何下载

Hugging Face | Search models, datasets, users... | Models | Datasets | Spaces | Community | Docs | Pricing

Datasets: bentrevett/multi30k | like 11

Tasks: Translation | Modalities: Text | Formats: json | Languages: English, German | Size: 10K - 100K | Libraries: Datasets, pandas, Croissant +1

Dataset card | Data Studio | Files and versions xet | Community 1

Dataset Viewer | Auto-converted to Parquet | API | Embed | Data Studio

Split (3)
train · 29k rows

Search this dataset

en string · *lengths* 15 – 205	de string · *lengths* 2 – 254
Two young, White males are outside near many bushes.	Zwei junge weiße Männer sind im Freien in der Nähe vieler Büsche.
Several men in hard hats are operating a giant pulley system.	Mehrere Männer mit Schutzhelmen bedienen ein Antriebsradsystem.
A little girl climbing into a wooden playhouse.	Ein kleines Mädchen klettert in ein Spielhaus aus Holz.
A man in a blue shirt is standing on a ladder cleaning a window.	Ein Mann in einem blauen Hemd steht auf einer Leiter und putzt ein Fenster.
Two men are at the stove preparing food.	Zwei Männer stehen am Herd und bereiten Essen zu.
A man in green holds a guitar while the other man observes his shirt.	Ein Mann in grün hält eine Gitarre, während der andere Mann sein Hemd ansieht.

Downloads last month 3,172

Use this dataset | Edit dataset card

Size of downloaded dataset files: 4.92 MB

Size of the auto-converted Parquet files: 2.5 MB

Number of rows: 31,014

Models trained or fine-tuned on bentrevett/mul...

or4cl3ai/Aiden_t5
Text Generation • Updated Oct 6, 2... • 889 • 18

neelimapreeti297/GermanToEnglish
Translation • 36.1M • Updated Apr 13, 2024 • 9

SUSTech-NLP/mclip_base
Feature Extraction • Updated Jan 23, 2024 • 2

任务要求—— 在实验报告中体现

- **基础要求**
  - 对数据进行预处理，train/valid/test已划分。
  - 实现并训练 RNN Seq2Seq 模型
    - Encoder + Decoder（LSTM或者GRU）
    - 保持参数量在合理范围内
    - 记录训练时间、损失曲线及验证集性能
  - 实现并训练 Transformer Seq2Seq 模型
    - 使用PyTorch nn.Transformer 或 自己实现（PE + MHA + FFN + 残差 + LN）
    - **参数量与 RNN 模型接近**
    - 记录训练时间、损失曲线及验证集性能
  - 对比相同参数量Transformer 和 RNN 的训练情况（时间、收敛、性能……）
  - 在测试集上统一评估两个模型，使用指标BLEU（BLEU-1, BLEU-2, BLEU-4），ROUGE-L，BERTScore（统一使用microsoft/deberta-large-mnli模型作为backbone）
    - 模型网址：https://huggingface.co/microsoft/deberta-large-mnli
    - 使用默认参数
  - 调整超参数，达到最佳性能
  - 分析两种模型各自的优劣，不得只做“概念性描述”，必须结合实验现象进行论证（可视化、实验数据、输出示例……）

计算 Bert Score
返回值为 Average F1

```python
from bert_score import score

cands = [
    "The cat sits on the mat.",
    "A man is playing guitar."
]

refs = [
    "A cat is sitting on the mat.",
    "Someone plays a guitar."
]

P, R, F1 = score(
    cands,
    refs,
    model_type="microsoft/deberta-large-mnli",  # 使用指定模型
    lang="en",
    verbose=True
)

print("Precision:", P.tolist())
print("Recall:", R.tolist())
print("F1:", F1.tolist())
print("Average F1:", F1.mean().item())
```

PROBLEMS OUTPUT DEBUG CONSOLE TERMINAL PORTS

```
(nobug) yujing@yujingdeMacBook-Pro gps % /usr/bin/python3 /Users/y
(nobug) yujing@yujingdeMacBook-Pro gps % python /Users/yujing/Stud
tokenizer_config.json: 100%|
config.json: 100%|
vocab.json: 899kB [00:00, 6.08MB/s]
merges.txt: 456kB [00:00, 34.5MB/s]
pytorch_model.bin: 100%|
calculating scores...
computing bert embedding.
100%|
computing greedy matching.
100%|
done in 0.18 seconds, 11.06 sentences/sec
Precision: [0.9470252990722656, 0.7915859222412109]
Recall: [0.9213104844093323, 0.8600835800170898]
F1: [0.9339909553527832, 0.8244143724441528]
Average F1: 0.879202663898468
(nobug) yujing@yujingdeMacBook-Pro gps %
```

加分项目——在实验报告中体现

- 在RNN模型中加入Attention，并进行比较分析
- 自己搭建简化版Transformer
- 使用各种方法优化生成质量（不举例子，自己探索）
- 实现并对比RNN/Transformer的更多变体（需提供参考文献）
- 更好的可视化（比如绘制注意力热力图、展示RNN的梯度范数变化、生成过程可视化……）
- ……

评分标准

项目	权重	评分细则
1. 代码实现（30分）		
- 模型结构合理、实现完整	10	能正确构建并运行
- 训练过程规范（含数据加载、训练循环、验证评估）	10	逻辑清晰，结构规范
- 代码规范（注释清晰、无冗余、结果可复现）	10	提供README运行说明
2. 模型性能（10分）		综合考虑参数量与性能，务必在实验报告中清晰体现（所以不要卷参数量）
3. 实验报告（50分）		
- 报告结构完整，条理清晰	12.5	章节齐全，逻辑流畅
- 有对模型原理、实验设置的说明	12.5	参数、优化方法等说明充分
- 有结果分析、可视化图表展示	12.5	训练曲线与性能对比……
- 有独立思考	12.5	不得只做“概念性描述”，必须结合实验现象进行论证
4. 创新（10分）		
- 见加分项目	10	体现在实验报告中，由助教酌情加分